

1. 데이터셋 생성

1.1 데이터 수집

- 출처: 농촌진흥청 「토마토 재배 가이드」, Cornell Extension 병해충 매뉴얼 등 공인 문헌 5종
- 생성 방법: Opus 4.1 모델을 이용한 토마토 재배 환경 질의응답(QA) 데이터 합성
- 구성 카테고리: 6개 (생육 관리, 병해충, 온습도 관리, 비료, 조명, CO₂ 등)

1.2 포맷 설계

프롬프트 형식

[STATUS: {센서상태}] {사용자질문}

답변 형식

[{경고여부}] {전문가답변} (1-2문장 내외)

1.3 품질 검증 (3단계)

- JSON 구조 및 필드 완전성 검사
- 중복 제거: 코사인 유사도 0.85 이상 항목 제거 (127개)
- 전문용어 사전 검증: 1,247개 항목 일치율 검증 → 평균 87.3%
 - 70% 미만 샘플 제거

최종 데이터셋 통계

- 평균 질문 길이: 18.3토큰
- 평균 답변 길이: 31.7토큰
- 고유 어휘: 2,847개 (전문용어 412개 포함)

2. 프루닝 (Pruning)

2.1 기본 전략

- 대상: FFN 뉴런만 제거
- 보존: Attention Head (레이어당 4개 뿐이라 제거 시 성능 급락)
- 최종 프루닝 비율: 25%

2.2 중요도 측정 방식

데이터 기반 활성화 측정

- 토마토 스마트팜 데이터 2,000개로 실제 활성화 측정
- SwiGLU 활성화 값 수집

3가지 지표 결합

지표	가중치	용도
평균 활성화	0.7	지속적 기여 뉴런 보호
최대 활성화	0.2	특정 상황 반응 뉴런
활동 비율	0.1	Dead neuron 탐지

2.3 레이어별 차등 보호

레이어 범위	스케일	전략
초기 (0-8)	0.6	범용 언어 패턴 → 적극적 제거
중간 (9-17)	1.0	기준값
후기 (18-25)	1.3	도메인 특화 지식 집중 → 보호

2.4 안전 장치

- 레이어당 최소 **800개 뉴런 유지**
- 레이어당 최대 **30% 제거 제한**
- 앞뒤 2개 레이어는 제거량 **50% 축소**
- Dead neuron 우선 제거

2.5 프루닝 실험 과정

Phase 1: 최적 프루닝 비율 탐색

- 5-15%: 너무 보수적
- 30%: 과도한 제거로 급격한 성능 저하
- **25% 선정** → 파라미터 14.5% 감소

Phase 2: 레이어별 차등 적용

- 초기 레이어(0-8): 스케일 0.2로 적극 제거
- 후기 레이어(18-25): 스케일 2.2로 보호

Phase 3: 가중치 최적화

- 평균 활성화: 0.8로 상향 (지속적 기여 뉴런 보호)
- 최대 활성화: 0.1로 하향 (보조 지표로 활용)
- 활동 비율: 0.1 유지 (Dead neuron 탐지용)
- **결과**: BLEU 점수 향상

3. LoRA 기반 미세조정

3.1 LoRA 적용 당위성

장점

- 1. 높은 학습 효율성: 전체 파라미터의 1% 미만만 학습
- 2. 추론 성능 저하 없음: 병합(merge) 후 추가 계산 오버헤드 없음
- 3. 효과적인 성능 복원: 프루닝 손실 복구 및 도메인 특화

3.2 하이퍼파라미터 설정

최적 구성

- Target Modules: q_proj , k_proj , v_proj , o_proj , up_proj , down_proj , gate_proj
- LoRA Alpha: 32
- LoRA Dropout: 0.05

학습 파라미터

- per_device_train_batch_size : 2
- gradient_accumulation_steps : 8 (Effective batch size: 16)
- num_train_epochs : 3
- learning_rate : 3×10^{-4}

3.3 Rank 실험 결과

Rank (r)	학습 파라미터 수	BLEU	ROUGE-L
4	~0.8M	0.0912	0.1985
8	~1.6M	0.1157	0.2193
16	~3.2M	0.1343	0.2384
32	~6.4M	0.1351	0.2399

분석 및 최종 선정

- r=4, 8: 표현력 부족, 성능 복구 불완전
- r=32: 성능 향상 미미, 파라미터 2배 증가로 비효율적
- r=16 선정: 성능과 효율성의 최적 균형점
 - BLEU: 0.0061 → 0.1343 (22배 향상)
 - ROUGE-L: 0.0999 → 0.2384 (2.4배 향상)

3.4 학습 환경 및 데이터

환경

- 플랫폼: Google Colab
- 하드웨어: CUDA GPU
- 베이스 모델: 프루닝된 Gemma3-1B-it

학습 데이터

- 형식: JSON (`finetuning_lora.json`)
- 구조: "instruction"과 "output" 키

학습 제약 및 최적화

- Batch size: 2 (GPU RAM 제약)
- Gradient accumulation: 8
- Epoch: 3 (3 이상 시 오버피팅 발생)

4. 4비트 양자화

4.1 양자화 기법

- 프레임워크: llama.cpp
- 포맷: GGUF
- 방식: Q4_K_M (4-bit block-wise quantization)

4.2 Q4_K_M 특징

- 가중치를 4비트 단위로 압축
- 블록별 스케일(scale)과 제로포인트(zero-point) 유지
- 연산 정확도 최대한 보존

4.3 양자화 프로세스

- 모델 병합: LoRA 어댑터 + 프루닝된 베이스 모델
- GGUF 변환: llama.cpp 활용
- 4bit 양자화 적용: Q4_K_M 기법

4.4 효과

- 메모리 절감: F32 대비 약 4배 감소
- 정밀도 손실: 최소화
- 추론 성능: 경량 디바이스에서도 안정적

5. 최종 결과

통합 최적화 효과

- ✓ **프루닝** → 파라미터 14.5% 감소
- ✓ **LoRA 파인튜닝** → 도메인 특화 및 성능 복원
- ✓ **4bit 양자화** → 메모리 75% 절감

최종 모델 특성

- 라즈베리파이 등 저전력 엣지 디바이스에서 실시간 추론 가능
- 토마토 스마트팜 도메인에 특화된 경량 LLM
- 안정적인 추론 성능 및 최소한의 지연시간