

0. 개요

본 보고서는 Edge Device 환경의 토마토 Smart Farm에서 Real-time inference가 가능한 Domain-specific SLM 개발 과정을 기술한다. Model 경량화와 성능 최적화를 위해 아래와 같은 4 단계 Pipeline을 적용한다.

1. Dataset Construction
2. Pruning
3. LoRA Fine Tuning
4. Quantization

해당 파이프라인을 통해 제한된 하드웨어 리소스 내에서 안정적인 성능 확보가 주 목표이다.

1. Dataset Construction

Domain-specific Model 학습을 위해 토마토 재배 환경에 대한 QA Dataset을 구축한다.

1.1. Data 수집

- 농촌진흥청: 토마토 재배 가이드
- Cornell Extension 병해충 메뉴얼
- ??
- ??
- ??

1.2. Data 합성

- Opus 4.1을 활용해 QA Data 합성
- Category
 - 생육 관리
 - 병해충
 - 온습도
 - 비료
 - 조명
 - 이산화탄소

1.3. Data Format(Prompt)

```
Q: [STATUS: {SENSOR_STATUS}] {UESR_QUESTION}
A: [{WARNING}] {ANSWER}
```

1.4. 품질 검증

데이터 신뢰도 및 품질 향상을 위해 아래와 같은 3단계 검증을 수행한다.

1. Structure: 모든 데이터가 유효한 JSON 구조와 필수 필드를 갖추었는지 검증
2. Deduplication: 코사인 유사도 0.85 이상인 중복 항목 127개 제거

3. Terminology Verification: 자체 구축 Terminology dictionary(1,247개)과 일치율 검증하여 평균 87.3% 달성
- 70% 미만 Sample 폐기

2. Pruning

Model Parameter 수를 줄여 inference efficiency 증대 위해 Pruning을 적용한다.

- 대상: Feed-Forward Network(FFN)의 Neuren만 제거 대상
 - 이유 및 증거가 타당하지 않음
- 보존: Attention Head는 Layer 당 4개로 수가 적어 제거 시 성능 저하가 크기에 보존
 - 증거 자료 필요
- 결과: 25%의 Pruning Rate가 성능과 Model Size 간 최적 균형점임을 확인
- Total Parameter 수 14.5% 감소

2.1. Nueren Importance

지표	가중치	Description
Average Activation	0.8	지속적으로 활성화되며 Model 핵심 기능에 기여하는 Nueren 보호
Maximum Activation	0.1	특정 상황에서만 반응하는 Nueren을 보조 지표로 활용
Activity Ratio	0.1	Dead Neuren 식별 및 우선 제거

2.2. Layer 별 차등 보호 전략

Layer Group	Landscape	Scale	Description
초기 Layer	0-8	0.2	범용 언어 패턴 담당하므로 적극적 Pruning
중간 Layer	9-17	1.0	기준 강도 Pruning
후기 Layer	18-25	2.2	도메인 특화 지식이 집중되어 있어 최대한 보호

2.3. 안정성 확보

- Layer 당 최소 800개 Nueren 유지
 - 이 수치인 이유 없음
- Layer 당 최대 제거율 30%로 제한
 - 이 수치인 이유 없음
- 특정 레이어 주변 제거량 50%로 축소해 급격한 변화 방지
 - 이 수치인 이유 없음
- Dead Neuron 우선 제거

3. LoRA Based Fine-Tuning

Pruned Model에 적용하여 개별 효과를 정량적으로 파악할 수 없다.

3.1. Best Hyperparameter

Item	Value
Target Modules	q, k, v, o, up, down, gate_proj
LoRA Rank	16
LoRA Alpha	2(Hardware)
Gradient Accumulation Steps	8(실질 Batch Size 16)
Epochs	3

3.3. Rank 실험 결과

Rank	Number of Learning Parameter	BLEU	ROUGE-L
4	약 0.8M	0.0912	0.1985
8	약 1.6M	0.1157	0.2193
16	약 3.2M	0.1343	0.2384
32	약 6.4M	0.1351	0.2399

Rank 16이 효율 및 성능 최적 균형점으로 판단하여 최종 채택

4. Quantization

1. Merge Model: Pruned Model에 학습된 LoRA Adapter를 Merge해 Total Model 생성
2. Change Format: Total Model을 llama.cpp를 이용해 GGUF Format으로 변환
3. Quantization: GGUF Model에 Q4_K_M Quantization 적용

4.1. Q4_K_M

다른 기법에 대한 언급이나 시도가 없음(최적이 아닐 수 있음)
가중치를 4bit로 압축하면서도 Block 별 Scale과 Zero-point를 유지하는 Block-wise Quantization.

- Memory 절감: 기존 F32 Model 대비 메모리 사용량 약 4배 감소
- 정밀도 손실 최소화

5. 결론

- Pruning: Parameter 14.5% 제거
 - LoRA Fine Tuning: 손실된 성능 복원 및 Domain 지식 주입
 - 4Bit Quantization: Memory 사용량 75% 절감
- 시도하지 않았으나 단순 연산 상 Raspberry Pi와 같은 저전력 Edge Device에서 Real-time inference가 가능할 것으로 예상